

Arquitectura Multimodal para la Integración de Datos Bioespaciales y Genómicos mediante Fusión en un Espacio Latente Z

Pipeline Computacional Experimental

Nadal Ferrá

Investigador Independiente

27 de agosto de 2026

Resumen

Proponemos una arquitectura computacional experimental inspirada en problemas de integración de datos paleogenómicos, diseñada para abordar el desafío de representar y fusionar datos bioespaciales heterogéneos mediante aprendizaje profundo. Detallamos la especificación de tres encoders especializados (genómico, geométrico y estratigráfico) y su proyección hacia un espacio latente común $Z \in \mathbb{R}^{N \times d_z}$ mediante fusión tardía basada en suma de proyecciones lineales. Definimos formalmente el problema de optimización, el mecanismo de concatenación de referencia y establecemos un protocolo de ablación controlado para evaluar empíricamente el comportamiento de esta arquitectura frente a enfoques unimodales, combinaciones parciales y estrategias de concatenación bajo presupuestos de parámetros comparables y múltiples semillas.

1. Introducción y Marco Teórico

La integración de datos heterogéneos aborda un desafío crítico en la ingeniería de características multimodales. El propósito de este trabajo es definir una especificación formal que transforme datos genómicos, geométricos y estratigráficos en un espacio tensorial común, orientado a su utilización posterior en tareas predictivas y transformando la información interna de cada modalidad antes de la integración.

2. Especificación de los Encoders y Construcción de Z

Para estructurar una arquitectura coherente, definimos tres componentes de codificación independientes que procesan las modalidades de entrada (para N muestras) antes de su fusión. Sean

$$D_{\text{DNA}} \in \mathbb{R}^{N \times p_{\text{DNA}}}, \quad D_{\text{spatial}} \in \mathbb{R}^{N \times p_{\text{spatial}}}, \quad D_{\text{strat}} \in \mathbb{R}^{N \times p_{\text{strat}}}$$

donde p_{DNA} , p_{spatial} y p_{strat} representan las dimensiones de las características de cada modalidad.

- **Encoder Genómico (E_{DNA}):** Procesa la composición de secuencias y las propiedades físico-químicas base (D_{DNA}) mediante bloques convolucionales 1D, generando una representación $E_{\text{DNA}} \in \mathbb{R}^{N \times d_1}$.

- **Encoder Geométrico (E_{spatial}):** A partir de una representación geométrica inducida mediante un mapeo helicoidal tridimensional y la construcción del Laplaciano de grafo $L = D - A$, procesa los autovalores espectrales y descriptores espaciales (D_{spatial}), mapeándolos a $E_{\text{spatial}} \in \mathbb{R}^{N \times d_2}$.
- **Encoder Estratigráfico (E_{strat}):** Analiza el sistema de integrales funcionales sobre los perfiles de profundidad e hidropatía ($D_{\text{stratigraphic}}$) mediante un perceptrón multicapa, proyectándolos a $E_{\text{strat}} \in \mathbb{R}^{N \times d_3}$.

Los encoders producen explícitamente:

$$E_{\text{DNA}} \in \mathbb{R}^{N \times d_1}, \quad E_{\text{spatial}} \in \mathbb{R}^{N \times d_2}, \quad E_{\text{strat}} \in \mathbb{R}^{N \times d_3}$$

La construcción del espacio latente compartido $Z \in \mathbb{R}^{N \times d_z}$ se implementa mediante un módulo de **fusión tardía mediante suma de proyecciones lineales**. Las proyecciones emplean matrices de pesos globales $W_1 \in \mathbb{R}^{d_z \times d_1}$, $W_2 \in \mathbb{R}^{d_z \times d_2}$ y $W_3 \in \mathbb{R}^{d_z \times d_3}$, combinadas por muestra x de la siguiente forma:

$$Z_\theta(x) = \sigma(E_{\text{DNA}}(x_{\text{DNA}})W_1^T + E_{\text{spatial}}(x_{\text{spatial}})W_2^T + E_{\text{strat}}(x_{\text{strat}})W_3^T + b)$$

donde $b \in \mathbb{R}^{d_z}$ es el sesgo y σ es la función de activación no lineal (GELU). Cada encoder transforma la información de su modalidad en una representación específica antes de realizar la integración hacia Z . (*Nota: futuras iteraciones podrán incorporar pesos adaptativos dependientes de la muestra $\alpha_i(x)$ mediante mecanismos de atención*).

3. Formulación del Problema de Aprendizaje y Tarea Predictiva

El flujo computacional completo del modelo se formaliza descomponiendo el conjunto total de parámetros del modelo $\theta = \{\theta_{\text{DNA}}, \theta_{\text{spatial}}, \theta_{\text{strat}}, W_1, W_2, W_3, \theta_g, b\}$ en los encoders y el módulo de predicción posterior g_θ :

$$\{D_{\text{DNA}}, D_{\text{spatial}}, D_{\text{strat}}\} \xrightarrow{\text{Encoders}} \{E_{\text{DNA}}, E_{\text{spatial}}, E_{\text{strat}}\} \xrightarrow{Z} Z \xrightarrow{\text{Predicción}} \hat{Y}$$

Definimos formalmente el modelo completo como $\hat{y} = f_\theta(x) = g_\theta(Z_\theta(x))$. Para concretar la tarea predictiva, asumimos una variable objetivo continua $Y \in \mathbb{R}^k$ (o $Y \in \mathbb{R}$ en el caso univariado). Definimos la función de pérdida por muestra basada en el error cuadrático medio:

$$L_{\text{MSE}}(\hat{y}, y) = \frac{1}{k} \|\hat{y} - y\|_2^2$$

El entrenamiento del sistema se plantea como el problema de optimización empírica:

$$\theta^* = \arg \min_{\theta} \frac{1}{|\mathcal{D}_{\text{train}}|} \sum_{(x,y) \in \mathcal{D}_{\text{train}}} L_{\text{MSE}}(g_\theta(Z_\theta(x)), y)$$

Asimismo, para evaluar el rendimiento global sobre cualquier partición $\mathcal{D}$, se define:

$$\text{MSE}(\mathcal{D}) = \frac{1}{|\mathcal{D}|k} \sum_{(x,y) \in \mathcal{D}} \|\hat{y}(x) - y\|_2^2$$

Como estrategia alternativa de fusión, se define el baseline de **Fusión por Concatenación Simple** mediante la unión de representaciones en la dimensión de características $H_{\text{concat}} = [E_{\text{DNA}} \parallel E_{\text{spatial}} \parallel E_{\text{strat}}]$. Por construcción, $H_{\text{concat}} \in \mathbb{R}^{N \times (d_1 + d_2 + d_3)}$. El predictor g_{concat} recibe esta representación y se dimensiona de forma que el número total de parámetros entrenables sea comparable al del modelo propuesto. La salida del baseline se define como $\hat{y}_{\text{concat}} = g_{\text{concat}}(H_{\text{concat}})$.

4. Estudio de Ablación y Protocolo Experimental

Para evaluar la contribución de cada componente y modalidad, se define un protocolo experimental controlado utilizando una partición estricta de los datos $\mathcal{D} = \mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{val}} \cup \mathcal{D}_{\text{test}}$, con $\mathcal{D}_{\text{train}} \cap \mathcal{D}_{\text{val}} = \mathcal{D}_{\text{train}} \cap \mathcal{D}_{\text{test}} = \mathcal{D}_{\text{val}} \cap \mathcal{D}_{\text{test}} = \emptyset$.

Todas las configuraciones experimentales utilizan exactamente las mismas particiones de muestras. El conjunto $\mathcal{D}_{\text{test}}$ se reserva exclusivamente para la evaluación final y no interviene en la selección de hiperparámetros, el criterio de parada temprana ni la selección del checkpoint. Las transformaciones de normalización se ajustan exclusivamente sobre $\mathcal{D}_{\text{train}}$ y se aplican posteriormente sobre $\mathcal{D}_{\text{val}}$ y $\mathcal{D}_{\text{test}}$.

Todos los modelos comparten el optimizador AdamW, tasa de aprendizaje inicial, criterio de parada temprana y presupuesto máximo de entrenamiento. Cada configuración se evaluará con S semillas aleatorias independientes, reportando la media y desviación estándar.

Modelo / Configuración	Información Utilizada	# Parámetros	MSE Val.	MSE Test
Solo Genómica (Baseline 1)	D_{DNA}	Pendiente	Pendiente	Pendiente
Solo Geometría (Baseline 2)	D_{spatial}	Pendiente	Pendiente	Pendiente
Solo Estratigrafía (Baseline 3)	D_{strat}	Pendiente	Pendiente	Pendiente
Combinación Parcial	$D_{\text{DNA}} + D_{\text{spatial}}$	Pendiente	Pendiente	Pendiente
Concatenación Simple (H_{concat})	$D_{\text{DNA}} + D_{\text{spatial}} + D_{\text{strat}}$	Pendiente	Pendiente	Pendiente
Modelo Propuesto (Fusión Proyectada Z)	$D_{\text{DNA}} + D_{\text{spatial}} + D_{\text{strat}}$	Pendiente	Pendiente	Pendiente

Cuadro 1: Esquema del estudio de ablación. Los valores de parámetros y MSE se determinarán tras la implementación y ejecución del protocolo experimental con S semillas independientes.

5. Conclusiones

Hemos presentado una especificación arquitectónica formal y matemáticamente definida para la integración de datos bioespaciales heterogéneos mediante encoders especializados y fusión tardía mediante proyecciones lineales. El diseño separa explícitamente la representación de cada modalidad de su integración en el espacio latente compartido Z y establece un baseline de concatenación simple para la comparación.

El protocolo experimental propuesto está diseñado para controlar la partición de los datos, evitar fugas de información y mantener condiciones de optimización comparables. Los siguientes pasos consisten en implementar la arquitectura, fijar hiperparámetros, ejecutar las ablaciones y reportar métricas agregadas junto con su variabilidad estadística.